

시공간적 변동이 공간·시공간 크리깅 추정에 미치는 영향

정 민¹, 유무상², 강혜윤¹, 조영철¹, 구형모^{3*}

¹서울시립대학교 공간정보공학과 석사과정생

²서울시립대학교 공간정보공학과 박사수료생

³서울시립대학교 공간정보공학과 부교수

Impacts of Spatio-Temporal Variation on Estimation of Spatial and Spatio-Temporal Kriging

Min Jeong¹, Musang Yoo², Hyeyun Kang¹, Youngchul Cho¹, Hyeongmo Koo^{3*}

¹Master Student, Department of Geoinformatics, University of Seoul, Seoul, Republic of Korea

²PhD Candidate, Department of Geoinformatics, University of Seoul, Seoul, Republic of Korea

³Associate Professor, Department of Geoinformatics, University of Seoul, Seoul, Republic of Korea

Abstract: Spatial kriging interpolates attributes at unobserved locations based on spatial autocorrelation, while spatio-temporal kriging extends it by incorporating temporal dimensions to reflect spatio-temporal interactions. Previous studies have shown that applying spatio-temporal kriging to spatio-temporal data improves estimation accuracy. However, because spatio-temporal kriging needs to simultaneously model both spatial and temporal autocorrelation, the nature of spatio-temporal variability may influence its accuracy. This study explores the impacts of spatio-temporal variations on the estimations of spatial and spatio-temporal kriging. In addition, it investigates the effects on kriging models that incorporate machine learning. Specifically, the study employs machine learning techniques with varying levels of flexibility, including random forest and boosting, in addition to conventional polynomial regression, to estimate first-order effects, while second-order effects are modeled using kriging. Kriging is applied to estimate nitrogen dioxide (NO₂) concentrations in Seoul during 2023, and estimation accuracy is assessed across two time points with distinct spatio-temporal variation. The analysis results show that estimating first-order effects with machine learning improves overall accuracy, with more flexible models yielding higher performance. When spatio-temporal variation is relatively smooth, spatio-temporal kriging performs better, whereas on days with high variability, spatial kriging, which considers only spatial variation at a single time point, demonstrates superior accuracy. Particularly, spatio-temporal kriging tended to overestimate concentrations overall at time points with high variability, while models without first-order effect estimation showed higher accuracy. In addition, the spatial distribution of the estimated concentrations was divided into two patterns depending on the method used to estimate the first-order effect: one exhibiting smooth and gradual trends, and the other showing abrupt and localized variations. This study empirically demonstrates how spatio-temporal variation and first-order estimation methods affect kriging-based prediction accuracy, underscoring the importance of selecting an appropriate kriging method based on the characteristics of spatio-temporal variation.

Keywords: Spatial kriging, Spatio-temporal kriging, Machine learning, Spatio-temporal variation, NO₂ concentrations

Received: April 12, 2025

Revised: April 22, 2025

Accepted: April 23, 2025

Published: April 30, 2025

Corresponding author:

Hyeongmo Koo

E-mail: hmokoo@uos.ac.kr

요약: 공간 크리깅(kriging)은 공간적 자기상관을 기반으로 관측되지 않은 지점의 속성값을 추정하며, 시공간 크리깅은 시간적 차원을 추가하여 시공간 상호작용을 반영한다. 기존 연구들은 시공간적 데이터에 시공간 크리깅을 적용하는 것이 일반적으로 추정 정확도가 더 높음을 밝혀왔다. 하지만 시공간 크리깅은 공간뿐 아니라 시공간적 자기상관을 동시에 모델링하므로, 시공간적 변동 양상이 시공간 크리깅 정확도에 영향을 미칠 가능성이 있다. 따라서 본 연구는 시공간적 변동 양상이 공간 및 시공간 크리깅의 추정 결과에 미치는 영향을 탐색한다. 더불어 기계학습을 결합한 크리깅에서의 시공간적 변동 양상이 미치는 영향도 확인한다. 이를 위하여 본 연구는 기존에 널리 활용된 다항회귀 외에 유연성이 높은 기계학습인 랜덤 포레스트(random forest)와 부스팅(boosting)을 활용하여 1차 효과를 추정하고, 나머지 2차 효과를 크리깅을 이용하여 추정한다. 추정 대상은 2023년 서울시 이산화질소 농도이며, 시공간적 변동 양상이 상이한 두 시점에 대한 추정을 평균 제곱근 오차를 통하여 평가하였다. 연구 결과 기계학습으로 1차 효과를 추정한 경우에 높은 추정 정확도를 보였으며, 유연성이 높을수록 정확한 추정을 제공하였다. 시공간적 변동이 작은 날에는 시공간 크리깅이 더 높은 추정 정확도를 보였으며, 반대로 변동이 큰 날에는 단일 시점의 공간적 변동만을 고려한 공간 크리깅이 우수한 성능을 나타냈다. 특히 변동이 큰 시점에서 1차 효과를 추정하지 않은 경우에는 시공간 크리깅이 더 높은 정확도를 보였으나, 전반적으로 시공간 크리깅에서 농도를 과대추정하는 경향이 나타났다. 또한, 1차 효과의 추정 방식에 따라 공간적 분포에서 부드럽고 완만한 경향이 나타나는 경우와, 국지적이며 급격한 변화 양상이 나타나는 경우로 구분되었다. 본 연구는 시공간적 변동과 1차 효과를 추정하는 방식이 크리깅 기반 공간 추정 정확도에 미치는 영향을 실증적으로 분석하였으며, 이를 통해 시공간적 변동에 따라 적합한 크리깅 기법 선택의 중요성을 시사한다.

주요어: 공간 크리깅, 시공간 크리깅, 기계학습, 시공간적 변동, 이산화질소

1. 서론

공간 크리깅(spatial kriging)은 공간적 인터폴레이션(interpolation) 기법 중 하나로, 관측 지점의 속성값을 바탕으로 관측되지 않은 지점에 대한 속성값을 추정하는데 사용된다(Cressie, 2015). 공간 크리깅은 1차 효과와 2차 효과의 결합으로 추정된다. 구체적으로 공간 크리깅은 공간적 자기상관(spatial autocorrelation)을 근거로, 주변에 있는 관측 지점을 이용하여, 다시 말해 관측지 간의 공간적 상호작용(2차 효과)을 이용하여 속성값을 추정하는 방식으로 진행된다. 크리깅에서 2차 효과의 모델링은 베리오그램(variogram)을 기반으로 이루어지며, 이 과정에서 공간적 상호작용의 정상성(stationarity) 가정의 확보가 필요하다. 정상성 가정은 일반적으로 관측치의 전역적인 경향성(1차 효과)을 제거하는 방식으로 확보하며, 최근 1차 효과의 추정에 다양한 기계학습이 사용되어 크리깅의 정확도 향상을 시도하고 있다(Zhan et al., 2018).

시공간 크리깅(spatio-temporal kriging)은 주변의 관측지뿐만 아니라 가까운 이전 시점의 관측값을 활용하여, 다시 말해 시공간적 상호작용을 활용하여 관측되지 않은 지점에 대한 속성값 추정의 정확성을 향상시키고자 한다(Júnez-Ferreira et al., 2023; Lin et al., 2018). 시공간 크리깅은 공간 베리오그램을 시공간 베리오그램의 추정으로 확장하여 2차 효과를 모델링하며, 이 역시 공간 크리깅과 같이 정상성의 가정을 기반으로 이루어진다. 최근 시공간 크리깅에 있어서도

1차 효과 추정에 기계학습을 결합하여 크리깅 정확도 향상을 시도하고 있다(Erten et al., 2022).

하지만 시공간 크리깅에서는 공간뿐 아니라 시공간적 자기상관을 동시에 모델링하므로, 시공간적 변동 양상이 시공간 크리깅 정확도에 영향을 미칠 가능성이 있다. 구체적으로 시공간 크리깅은 공간과 시간상에서 인접한 관측치 모두가 추정에 영향을 미치며, 동시에 시공간상에서의 완만한 변화를 가정한다. 따라서 시공간적으로 급격하게 변동하는 현상 혹은 시점에서는 인접한 이전 시점의 관측치를 고려하는 것이 오히려 추정에 악영향을 끼칠 수 있다. 최근 기계학습을 이용한 1차 효과 추정은 뛰어난 정확도를 보이고 있으나, 시공간적 전역적 경향 추정 과정에서 시간상으로 인접한 시점의 관측치를 더욱 중시하는 경향이 있다(Meyer et al., 2018). 이러한 특성으로 인하여 시공간적 현상의 급격한 변동은 기계학습을 결합한 시공간 크리깅 결과에서는 더 큰 정확도 하락을 야기할 수 있다.

따라서 본 연구는 시공간적 변동 양상이 공간 및 시공간 크리깅의 추정 결과에 미치는 영향을 탐색한다. 더불어 1차 효과 추정에서 기계학습의 선택과 시공간적 변동 양상 간의 관계 역시 탐색해보고자 한다. 이를 위하여 먼저 각각 공간과 시공간 크리깅에 기계학습을 결합한 모형을 적용하여, 이산화질소(nitrogen dioxide, NO₂) 농도를 추정한다. 그 후 NO₂ 농도 추정 결과를 시공간적 변동 양상이 다른 두 시점별, 기계학습별로 비교 분석한다.

2. 연구 방법 및 자료

본 연구의 목적은 시공간적 변동 양상이 공간 및 시공간 크리깅의 추정치에 미치는 영향을 탐색하는 것이다. 이를 위하여 공간 크리깅과 시공간 크리깅을 시행하며, 구체적으로 1차 효과의 추정에 기계학습을 적용하고, 2차 효과를 공간 크리깅과 시공간 크리깅으로 추정하여 정확도를 비교한다. 따라서 본 장에서는 2차 효과를 추정하기 위한 공간 크리깅과 시공간 크리깅에 대하여 설명하고, 베리오그램과 코베리오그램(covariogram)에 대한 요소를 기술한다. 다음으로 1차 효과의 추정을 위한 기계학습의 하이퍼파라미터 튜닝(hyperparameter tuning)에 대하여 설명한다. 마지막으로 연구 범위와 기계학습에 활용되는 반응 변수와 입력 변수의 투입에 대하여 기술하고, 추정 정확도 평가 방식에 대하여 설명한다.

공간 크리깅은 관측 지점의 속성값을 바탕으로 관측되지 않은 지점에 대한 속성값을 추정하기 위해 사용한다. 구체적으로 공간 크리깅은 식(1)에 따라 전역적 추세를 설명하는 1차 효과($m(s)$)와 국지적 상호작용을 나타내는 2차 효과($V(s)$)로 공간적 변동을 분해하여 모델링한다(Bailey and Gatrell, 1995). 더불어 공간 크리깅은 1차 및 2차 효과의 추정 방식에 따라 구분되며, 대표적으로 단순(simple) 크리깅, 오디너리(ordinary) 크리깅, 유니버설(universal) 크리깅이 있다. 단순 크리깅은 1차 효과를 외부에서 미리 알고 있다는 가정으로 2차 효과만을 모델링한다. 오디너리 크리깅과 유니버설 크리깅은 1차 효과와 2차 효과를 동시에 모델링하며, 각각 동질적인 1차 효과와 이질적인 1차 효과를 가정한다(Chiles and Delfiner, 2012). 특히 최근에는 1차 효과를 기계학습을 이용하여 추정한 후, 오디너리나 단순 크리깅과 결합하는 방식도 활용된다(Shao et al., 2020).

$$Z(s) = m(s) + V(s) \quad (1)$$

시공간 크리깅은 공간 크리깅에 시간을 고려하여 공간과 시간의 상호작용을 통합적으로 고려하여, 관측되지 않은 지점에서의 속성값 추정에 정확도 향상을 시도한다. 기존의 공간 크리깅 기반 접근법은 시공간적으로 연속된 현상을 특정 시점에서 정적인 효과로 단절하는 경우가 일반적이었기 때문에(An et al., 2015), 시간에 따른 속성값의 변화와 시공간적 상호작용을 충분히 반영하기 어렵다는 한계가 존재한다. 시공간 크리깅은 시공간적 변동을 전역적인 시공간적 1차 효과와 국지적인 시공간적 2차 효과로 분해한다(식 2). 구체적으로 시공간적 2차 효과는 공간적 효과($V_s(s)$), 시간적 효과($V_t(t)$) 그리고 시공간적 효과($V_{st}(s, t)$)를 통합적으로 반영함으로써 시공간적 변동을 추정하며(Heuvelink and Griffith, 2010), 이를 통해 추정값의 정확도 향상을 유도한다(식 3).

$$Z(s, t) = m(s, t) + V(s, t) \quad (2)$$

$$V(s, t) = V_s(s) + V_t(t) + V_{st}(s, t) \quad (3)$$

정상성의 가정은 크리깅의 전제 조건으로 이를 위해서는 1차 효과의 추정이 수반되어야 하며(Journel and Rossi, 1989), 이 과정에 다양한 기계학습이 활용될 수 있다. 2차 효과의 모델링에서 정상성은 기본 가정이 되며, 이는 공간적 자기상관의 양상이 절대적 위치와 무관하고, 상대적 위치에만 의존한다는 것을 의미한다(Bailey and Gatrell, 1995). 따라서 크리깅의 추정 정확도를 높이기 위해서는 정상성에 기반한 2차 효과의 추정이 필요하며, 이는 1차 효과를 추정하여 전역적 경향성을 제거하는 방식으로 진행된다. 전통적 방법론에서는 이 과정에서 주로 전역적 경향면법을 활용한다. 전역적 경향면법은 전반적인 공간적 변동을 단순하게 설명할 수 있으나, 유연성이 낮기에 복잡한 공간적 효과와 시공간적 효과의 모델링에서 한계를 가진다. 이러한 한계를 극복하기 위하여 유연성이 높은 기계학습을 1차 효과 추정에 활용함으로써 추정 정확도를 향상하고자 하는 접근이 다양한 분야에 활용되고 있다(Li et al., 2011; Shao et al., 2020; Zhan et al., 2018).

베리오그램의 모델링은 2차 효과 추정의 핵심이 된다. 공간 크리깅에서 베리오그램은 공간적 자기상관을 정량화하며, 너겟(nugget), 실(sill) 그리고 레인지(range)를 이용하여 공간적 변동을 표현한다. 구체적으로 너겟은 거리의 차이가 0에서 나타나는 이질성의 정도이며, 다시 말해 가까운 거리에서의 변동을 나타낸다. 레인지는 공간적 자기상관이 존재하는 임계 거리로, 그 이상의 거리에서는 공간적 자기상관이 존재하지 않으며, 실은 임계 거리에서의 이질성 정도를 나타낸다. 베리오그램은 이러한 구조를 바탕으로 크리깅에서 공분산 행렬 구성의 핵심적인 역할을 하며, 모형 적합을 통해 공간적 효과를 수치화한다. 또한, 공간 현상의 형태에 따라 적절한 함수 형태(구형(spherical), 지수(exponential), 가우시안(Gaussian) 모형)을 선택할 수 있으며, 본 연구에서는 일반적으로 널리 이용되며, 공간적 자기상관이 일정 거리까지 유지되다가 그 이후로는 사라지는 것을 가정하는 구형 모형을 이용한다(Wackernagel, 2003).

시공간 크리깅은 시공간 공분산 모형을 이용하여 시공간적 자기상관의 구조를 반영하는 시공간 베리오그램을 기반으로 추정된다. 대표적인 시공간 공분산 모형은 분리(separable), 곱-합(product-sum), 거리 기반(metric), 합-거리(sum-metric), 단순 합-거리(simple sum-metric) 모형이 있다. 단순-합 거리 모형은 공간, 시간, 시공간 베리오그램과 공통된 너겟 값으로 구성되어 각각의 실과 레인지를 추정한다. 단순 합-거리 모형은 공간적 효과와 시간적 효과를 모델링함과 동시에 각 효과의 상호작용 효과를 고려함으로써 효율적인 공분산 모형의 추정이 가능하다(Gräler et al., 2016). 따라서 본 연구에서는 합-거리 모형의 공간, 시간, 시공간 너겟을 하나의 항으로 축소하여 계산이 안정적이고 효율적인 단순 합-거리 모형을 활용한다.

나아가 본 연구는 기계학습을 이용하여 1차 효과를 추정하고, 특히 시간 축의 적용이 추정 정확도에 미치는 영향을 기계학습의 유연

성에 따라 달리 추정하고 평가한다. 이를 위하여 기계학습은 유연성을 달리하는 다항회귀모형(Polynomial Regression, PR), 랜덤 포레스트(Random Forest, RF) 그리고 부스팅(Boosting, BT)을 활용한다. PR은 일반적으로 널리 활용되는 방법으로, 단순하고 해석이 용이한 1차 효과 추정을 제공한다. RF는 의사결정나무 기반의 앙상블 모형으로 배깅(bagging)에 기반하여 의사결정나무의 과적합 가능성을 낮추며, 예측 정확도를 높인다. 또한 의사결정나무 간의 상관성을 낮추기 위하여 전체 입력 변수 중 일부를 선택하여 예측에 활용함으로써 과적합을 방지한다(Andriy, 2019). RF는 각 단계에서 훈련에 이용되지 않은 샘플인 Out-of-bag을 이용하여 하이퍼파라미터를 추정한다. BT는 의사결정나무 기반의 앙상블 모형이며, 나무의 개수를 늘려가며 학습률만큼 모형의 오차를 줄인다(Natekin and Knoll, 2013). 학습률 하이퍼파라미터가 이전 모형의 오차를 얼마나 학습하는지를 조정하며, 본 연구에서는 과적합을 방지하고 예측 성능의 안정성을 확보하기 위해서 0.01의 값으로 고정한다. 상호작용 깊이는 3, 4, 5로, 나무의 수는 공간 크리깅의 경우 100에서 1,000까지 100씩 늘려 추정한다. 시공간 크리깅의 경우에는 복잡한 시공간 변동을 포착하기 위하여 최대 나무의 수를 5,000까지 100씩 늘려가며 추정한다. BT 모형의 최적 하이퍼파라미터는 5-폴드 교차 검증을 이용하여 추정한다.

구체적으로 연구는 다음과 같은 자료를 활용한다. 인터플레이션의 대상은 NO_2 이며, NO_2 는 심혈관 질환 및 호흡기 질환에 악영향을 미치기에, 이의 정확한 분포 추정은 NO_2 관리 및 발생원 탐지에 도움을 주어, 궁극적으로 해당 지역의 보건 환경 개선에 기여한다. 나아가 NO_2 의 분포는 고도와 같은 공간적 변수의 영향과 풍향 및 풍속과

같은 시공간적 영향에 의해 달라지기에(Van Zoest et al., 2020), 공간 크리깅과 시공간 크리깅의 추정 결과를 비교하기에 적합하다. 연구 데이터 수집을 위하여 에어코리아(Korea Environment Corporation, 2023)에서 제공하는 대기오염물질 최종확정 자료를 일평균으로 집계하여 추정에 활용한다. 해당 자료는 2023년 1월 1일부터 2023년 12월 31일까지의 일평균 NO_2 농도를 포함한다. 공간적 외삽(extrapolation)으로 인한 정확도 하락 가능성을 낮추기 위하여 연구 지역인 서울시 경계로부터 7 km 이내에 위치한 관측 지점을 일부 활용한다. 구체적으로 연구에 이용한 관측 지점은 서울시 내부의 관측 지점 총 40개소와 외부의 관측 지점 총 31개소를 활용하며, 사용 가능한 관측값의 유무와 시점에 따라서 활용된 관측 지점에는 차이가 존재한다(Fig. 1a).

1차 효과 추정을 위한 기계학습에 이용되는 입력변수는 공간적 변동을 설명하기 위하여 X 좌표, Y 좌표와 다항식 변환 경향도 고려할 수 있도록 1-3차 다항변환항을 활용한다. 또한, 고도의 영향을 고려하기 위하여 90 m 해상도의 수치표고모형을 활용한다. 시간적 변동을 고려하기 위하여 시공간 크리깅의 기계학습은 NO_2 농도가 가장 높은 날인 1월 11일로부터의 시간적 거리를 활용하며(Fig. 1b), 유연성이 상대적으로 낮은 PR은 시간적 거리의 1-3차 다항변환항을 추가로 활용한다. 1차 효과는 기계학습의 유연성에 따라 달리 추정하고, 관측치와 1차 효과 추정값의 차이에 대하여 크리깅 추정 과정을 거친다. 추정 정확도는 하나의 관측치가 검정에 이용되고 나머지로 훈련을 하는 Leave-one-out Cross-Validation (LOOCV)을 활용하여, 각 관측치와 추정값의 평균 제곱근 오차(Root Mean Square Error, RMSE)를 계산하여 도출한다.




Fig. 1. Spatial and temporal characteristics of the air quality data. (a) Spatial distribution of air quality monitoring stations. (b) Daily variation in average NO_2 concentration.

3. 연구 결과 및 토의

본 연구는 시공간적 변동 양상이 크리깅 추정 정확도에 미치는 영향을 평가하기 위하여, 두 시점에서의 NO₂ 농도를 공간 크리깅과 시공간 크리깅을 이용하여 추정하고 비교한다. 본 장에서는 첫째로, 시점 비교를 위한 시점의 선택에 대하여 기술한다. 다음으로, 시공간적 효과 고려 여부에 따라 다르게 추정된 공간 및 시공간 베리오그램 요소에 대하여 설명한다. 마지막으로, 기계학습 기법별과 크리깅 기법별로 추정 시점에 따른 RMSE 기반의 추정 정확도와 공간적 분포를 지도화하여 추정 양상을 비교한다.

먼저 본 연구에서는 NO₂ 농도와 시공간적 변동을 고려하여 추정 시점을 지정한다. 구체적으로 일평균 NO₂ 농도가 60.76 ppb로 가장 높은 날인 1월 11일(이하 1월)과 일평균 NO₂ 농도가 7.31 ppb로 상대적으로 낮은 값을 보인 7월 23일(이하 7월)로 지정한다. NO₂ 농도는 일반적으로 겨울과 봄에 높으며, 여름에는 상대적으로 낮는데(Fig. 1b), 이는 NO₂의 생애주기와 연관된다. 구체적으로 NO₂의 생애주기는 태양 복사량과 대기 화학 반응의 영향을 받으며 겨울철이 여름철보다 약 3배 이상 길게 유지된다(Shah et al., 2020). 즉, 1월은 NO₂ 농도의 생애주기가 상대적으로 길어, 시공간에 따른 변동이 작으면서 높은 농도를 보이는 시점이며, 7월은 시공간적으로 급격한 변동을 보이면서 낮은 농도를 보이는 시점이다.

3.1. 베리오그램 추정 결과

다음은 베리오그램의 추정 결과이다. 공간 베리오그램은 NO₂ 농도의 공간적 구조를 나타내며, 이는 추정 시점과 1차 효과의 추정 방법에 따라 다른 추정 양상을 보인다(Table 1). 먼저 추정된 실 값은 모든

기법에서 NO₂ 농도가 높은 1월이 7월보다 높게 나타난다. 구체적으로 기계학습을 이용하여 1차 효과를 추정한 PR, RF, BT 공간 크리깅(PR-, RF-, BT- Spatial Kriging, PRSK, RFSK, BTSTK)의 실 값이 기계학습 과정을 거치지 않은 오디너리 공간 크리깅(Ordinary Spatial Kriging, OSK) 기법보다 낮은 값을 보인다. 두 시점 모두 의사결정나무 기반 앙상블 기법인 RF와 BT에서 실 값이 특히 작게 추정되는데, 이는 상대적으로 유연한 기계학습이 1차 효과의 변동을 세밀하게 포착하기 때문인 것으로 판단된다.

레인지 값도 대체로 기계학습으로 1차 효과를 추정한 기법에서의 추정치가 작은 경향을 보인다. 구체적으로 1월은 BTSTK (1,131.57), RFSK (2,258.96), PRSK (2,663.01) 그리고 OSK (9,643.74)의 순으로 레인지를 길게 추정한다. 7월은 RFSK (1,006.73), BTSTK (1,077.87), OSK (1,422.40) 그리고 PRSK (2,386.70) 순으로 긴 레인지를 추정한다. 레인지 값의 추정에서도 실 값의 추정과 비슷하게 RFSK와 BTSTK가 두 시점 모두에서 상대적으로 작은 값을 보인다. 이러한 경향은 유연한 기계학습을 이용한 1차 효과의 추정으로 작아진 실 값으로 인하여 보다 국지적인 변동만을 고려하기 때문인 것으로 추측된다.

시공간 베리오그램의 파라미터 값은 공간 베리오그램과 비슷하게 1차 효과 추정 방법에 따라 다른 양상을 보인다(Table 2). 시공간 베리오그램은 시점에 따라 독립적으로 추정되는 공간 베리오그램 파라미터 추정치와 달리 시간의 연속성을 고려하며, 본 연구에서는 시간 지연을 0일에서 14일까지 하루 간격으로 고려한다. 공간 간격은 1,500 m로 15,000 m까지 고려한다. 시공간적 효과를 고려한 시공간 베리오그램은 공간 베리오그램보다 기계학습에 따른 추정값의 차이가 두드러진다. 구체적으로 공간 차원의 실 값은 RFSTK (0.43), BTSTK (1.00), PRSTK (13.88) 그리고 OSTK (14.86)의 값을 보이고,

Table 1. Comparison of spatial kriging parameters across machine learning models and time points

Parameter	Date	OSK	PRSK	RFSK	BTSTK
Sill (ppb)	January 11	53.40	33.93	8.21	13.23
	July 23	5.25	6.80	1.58	2.85
Range (m)	January 11	9,643.74	2,663.01	2,258.96	1,131.57
	July 23	1,422.40	2,386.70	1,006.73	1,077.87

OSK: Ordinary Spatial Kriging, PRSK: Polynomial Regression Spatial Kriging, RFSK: Random Forest Spatial Kriging, BTSTK: Boosting Spatial Kriging.

Table 2. Spatio-temporal kriging parameters across machine learning models

Method	OSTK	PRSTK	RFSTK	BTSTK
Spatial sill (ppb)	14.86	13.88	0.43	1.00
Spatial range (m)	2,602.59	2,458.70	1,498.67	529.10
Temporal sill (ppb)	68.53	70.41	3.13	2.65
Temporal range (days)	1.87	1.76	0.77	1.73

OSTK: Ordinary Spatio-Temporal Kriging, PRSTK: Polynomial Regression Spatio-Temporal Kriging, RFSTK: Random Forest Spatio-Temporal Kriging, BTSTK: Boosting Spatio-Temporal Kriging.

Table 3. Comparisons of RMSE across machine learning models and time points

Time point	Method	Ordinary	Polynomial regression	Random forest	Boosting
Jan. 11th	Spatial kriging	6.38	6.26	3.07	3.69
	Spatio-temporal kriging	5.93	5.72	2.18	3.42
July 23rd	Spatial kriging	2.45	2.38	1.21	1.72
	Spatio-temporal kriging	2.34	2.82	2.89	3.21

시간 차원의 실 값은 BTSTK (2.65), RFSTK (3.13), OSTK (68.53) 그리고 PRSTK (70.41) 순으로 크게 추정된다. 공간 베리오그램의 양상과 비슷하게 상대적으로 모형 유연성이 높은 RFSTK와 BTSTK가 공간적, 시간적으로 모두 작은 실 값을 추정하는 경향을 보인다. 레인지 값도 공간은 BTSTK (529.10), RFSTK (1,498.67), PRSTK (2,458.70) 그리고 OSTK (2,602.59)의 순으로, 시간은 RFSTK (0.77), BTSTK (1.73), PRSTK (1.76) 그리고 OSTK (1.87) 순으로 길게 추정하며 기법 간의 차이는 미미하다. 하지만 실과 레인지 값이 OSTK와 PRSTK에서 상대적으로 크게 추정된다는 점은 두 모형이 2차 효과 추정을 보다 전역적이면서 큰 규모의 변동으로 설명함을 의미하며, 이는 공간 베리오그램에서도 동일한 경향을 보인다.

3.2. 시공간적 변동에 따른 전역적 모형 정확도 비교 분석

다음은 공간 크리깅과 시공간 크리깅 간의 정확도 비교 결과이다. 먼저 시공간적 변동 양상에 따른 정확도 비교 결과, 공간 크리깅과 시공간 크리깅의 정확도는 시공간적 변동 양상에 따라 상이하다. Table 3은 서울 내부에 위치한 관측 지점에서의 각 시점별 관측값과 추정값의 RMSE를 LOOCV로 계산한 결과를 나타내는 표이며, 볼드체는 상대적으로 높은 정확도를 보이는 모형을 의미한다. 구체적으로 1월에는 시공간 크리깅이 공간 크리깅보다 높은 추정 정확도를 보인 반면, 7월에는 전반적으로 공간 크리깅의 추정 정확도가 높게 나타난다. 특히 1월에는 1차 효과 추정을 위한 기계학습 적용 여부와 기법과 관계없이 시공간 크리깅이 더욱 높은 정확도로 추정하고, 7월에 기계학습을 적용한 경우에서 공간 크리깅이 더욱 우수한 성능을 보인다. 이러한 추정 정확도의 경향은 시공간적 변동 양상의 차이 때문인 것으로 판단된다. 구체적으로 1월에는 NO₂ 농도의 시공간적 변동이 상대적으로 작기 때문에, 시공간적 변동의 연속성을 고려하는 시공간 크리깅이 더욱 정확한 추정을 제공한 것으로 판단된다. 7월에는 NO₂ 농도가 낮으며 시공간적으로 급격한 변동을 보이기 때문에, 시간적 효과를 제거한 공간 크리깅이 더 높은 정확도를 보인 것으로 판단된다.

나아가 1차 효과 추정 방식은 공간과 시공간 크리깅의 전체 추정 정확도에 영향을 미친다. 대체로 유연한 기계학습 모형이 1차 효과 추정 시 변동을 세밀하게 포착하는 경향을 보인다. 시기에 따라서는, 1월에는 시공간 크리깅에서 RFSTK (2.18), BTSTK (3.69), PRSTK

(5.72) 그리고 OSTK (5.93)의 순으로 낮은 RMSE를 보인다. 이러한 경향은 7월의 공간 크리깅에서도 유사하게 나타나지만, 기계학습을 통해 공간적 1차 효과를 추정된 경우에만 적용된다. 구체적으로 RFSK (1.21), BTSK (1.72) 그리고 PRSK (2.38)의 순으로 높은 추정 정확도를 보인다. 반면, 1차 효과를 추정하지 않은 OSK와 OSTK의 경우에는 RMSE가 각각 2.45와 2.34로, 시공간 요소를 2차 효과 모델링에 반영한 시공간 크리깅에서 상대적으로 높은 정확도를 보인다. 이는 시공간적 구조를 2차 효과에 반영함으로써, 1차 효과를 추정하지 않은 상황에서도 공간 크리깅보다 정확한 추정이 가능한 것으로 판단된다.

3.3. 시공간적 변동 양상에 따른 국지적 모형 정확도 비교 분석

추정된 NO₂ 농도의 공간적 분포는 공간 크리깅과 시공간 크리깅 그리고 1차 효과의 추정 방식에 따라 차이를 보인다. 먼저 1월의 추정된 NO₂ 농도는 공간과 시공간 크리깅 기법에서 비슷한 추정 양상을 보인다. 구체적으로 두 기법 모두 서남권과 동남권 일부 지역에서 높은 농도를, 중부 도심권에서는 낮은 농도로 추정하는 경향을 보인다. 이는 남산이 위치한 중구의 높은 고도로 인하여 NO₂ 농도가 상대적으로 낮게 추정된 것으로 판단된다.

이 시기에는 1차 효과의 추정 방식에 따라서 크리깅 결과의 차이가 상대적으로 더 크게 나타나며, 이 결과는 기계학습별 시공간적 변동 양상을 고려하는 방식의 차이에 기인한 것으로 판단된다. 먼저 동질적 1차 효과를 가정하는 오디너리 크리깅과, PR로 1차 효과를 추정한 크리깅의 추정 결과는 전반적으로 완만한 공간적 추정 경향을 보인다. 이 중 OSK가 공간적 2차 효과만을 고려하여 공간적으로 군집되어 있으며 경향성이 넓은 범위로 분포한다(Fig. 2a). 반면 OSTK는 시공간 2차 효과를 반영함에 따라 관측 지점을 중심으로 동심원 형태로 추정 값의 감소 경향을 나타낸다(Fig. 2b). PRSK와 PRSTK는 전반적으로 북쪽에서 남쪽 방향으로 농도가 증가하는 경향을 보이며 중부 도심 일부 지역에서는 낮은 농도를 추정한다(Figs. 2c, d). 특히 PRSTK는 PRSK에 비하여 남동 방향으로 추정 값이 높아지면서 동북권역에서의 농도가 연속적으로 이어지는 경향을 보이며, 고도에 따른 미세한 농도 차이도 반영된다. 이러한 추정 경향은 공간 베리오그램에서 추정된 실 및 레인지 값이 시공간 베리오그램에 비해 더 크

고 넓게 나타나, 기계학습과 공간 크리깅에서 2차 효과를 넓고 완만하게 추정된 결과로 판단된다.

RF와 BT 기반 크리깅 추정 결과는 상대적으로 급격한 공간적 변동을 보인다. 이들은 PR 기반 크리깅과 유사한 공간 분포를 보이면서, 국지적으로 RFSTK는 특히 서남권에서 높은 농도와 동북권의 연속적인 농도 변화 경향을 보인다(Figs. 2e, f). 반면, BTSTK와 BTSTK 간의 추정 분포는 큰 공간적 분포의 차이를 보이며, BTSTK는 공간적으로 더 균질된 추정과 함께 중부 도심권에서의 농도를 높게 추정한다. BTSTK는 상대적으로 급변하면서 국지적인 추정 경향과 함께 선형

으로 농도가 높게 나타나는 지역도 관찰된다(Figs. 2g, h). 구체적으로 국지적으로 급변하는 추정 경향은 기계학습 모형의 유연성으로 인해 1차 효과의 추정 과정에서 세밀한 변동까지 모델링하여 공간 또는 시공간적 2차 효과는 상대적으로 좁은 범위에서 추정된 것으로 해석된다. 더욱이 나무기반 모형은 특정 값을 기준으로 예측값이 급격하게 변하는 특성을 지니고 있어, BT와 RF 기반 크리깅에서 선형성이 확인된다.

다음은 7월의 결과이다. 이 시기는 상대적으로 NO₂ 농도의 시공간적 변동이 크기 때문에, 공간과 시공간 크리깅 간의 결과의 차이가




Fig. 2. Comparison of NO₂ level estimations on January 11th. (a) OSK estimation. (b) OSTK estimation. (c) PRSK estimation. (d) PRSTK estimation. (e) RFSK estimation. (f) RFSTK estimation. (g) BTSTK estimation. (h) BTSTK estimation.

크다. 이 시기 대부분의 기법에서 공간 크리깅이 시공간 크리깅보다 우수한 성능을 보인다. 이는 시공간 변동이 큼에도 불구하고 시공간 크리깅이 이전 시기의 NO_2 농도를 현재 시점의 인터폴레이션에 활용하기 때문이다. 구체적으로 특정 위치에서 두 변수의 표준화된 값을 곱하여 상관관계를 표현하는 국지적 상관관계수(local Pearson's R) (Lee, 2001)를 계산한 결과, 연구 시점과 그 전날과의 상관관계가 음수로 나타나는 지점이 존재한다. 구체적으로 가장 큰 음의 국지적 상관관계수 값은 -0.44 이며, 값이 음수로 나타나는 지역은 주로 서울 남부지역과 서북권 인근에 위치한다. 해당 지역은 시공간적 변동이 크

게 나타난 지역으로, 이를 고려하지 않고 완전한 시공간적 변동을 가정하여 시공간 크리깅을 추정할 경우 정확도 하락을 야기할 가능성이 있다. 구체적으로 현재 시점만을 반영한 공간 크리깅은 동북권역에서 높은 농도로 추정하는 경향이 있는 반면, 시공간 크리깅은 이전 시기의 NO_2 농도가 상대적으로 높게 분포하기에 전반적으로 과대 추정의 경향을 보이며, 동남권역에서 고농도 지역이 군집하는 형태로 나타난다.

시공간적 변동 양상에 따른 기계학습별 추정 결과의 차이를 비교하면 다음과 같다. 먼저 OSK는 OSTK보다 낮은 추정 정확도를 보이며,




Fig. 3. Comparison of NO_2 level estimations on July 23rd. (a) OSK estimation. (b) OSTK estimation. (c) PRSK estimation. (d) PRSTK estimation. (e) RFSK estimation. (f) RFSTK estimation. (g) BTSK estimation. (h) BTSTK estimation.

추정된 NO₂ 공간적 분포 역시 차이를 보인다. OSK는 관측 지점을 중심으로 국지적인 동심원 형태의 감소 경향을 나타낸다(Fig. 3a). 반면, OSTK는 상대적으로 더 넓고 완만한 분포를 보인다(Fig. 3b). 이러한 차이는 베리오그램의 공간적 레인지 값 차이에서 기인하며, OSK는 OSTK에 비해 더 짧은 레인지 값을 나타내, 공간적 자기상관이 미치는 범위를 상대적으로 좁게 추정함을 의미한다. PR 기반 기법에서는 PRSK가 PRSTK보다 높은 추정 정확도를 보이며, 동북권과 서남권의 일부 지역에서 상대적으로 높은 농도 추정이 나타난다. PRSTK는 상대적으로 과대추정의 경향을 보이며 남부 지역에서 고농도 분포가 두드러진다. 두 기법은 서남권 일부 지역에서 공통적으로 국지적인 고농도 추정을 보인다(Figs. 3c, d).

양상을 기반 크리깅 기법에서는 공간 크리깅과 시공간 크리깅 간 추정된 NO₂의 공간적 분포 양상이 상반되게 나타난다. 이는 현재 시기의 농도 추정에 있어, 공간 크리깅이 현재 시기의 NO₂만을 이용한 반면 시공간 크리깅은 양상을 기반 1차 효과 추정을 통해 이전 시기의 NO₂를 반영한 결과이다. 그 결과 RFSK와 BTSTK는 PRSK와 유사하게 동북권과 서남권의 일부 지역에서 고농도를 보이나, 서남권에서는 남북 방향으로 공간적으로 급격히 변화하는 양상과 함께 고농도 분포가 나타난다는 점에서 차별된다(Figs. 3e, g). 시공간 변동을 고려한 RFSTK와 BTSTK는 동남권에서 고농도 추정이 집중되어 나타나며, 일부 서남권에서는 급격하고 국지적인 농도 변화가 나타난다(Figs. 3f, h). 특히, 나무 기반의 양상불 모형은 특정한 값을 기반으로 예측값이 급격히 달라지는 특성으로 인하여, 공간적 변동이 급격하고 불연속적으로 나타날 수 있다. 이러한 1차 효과 추정 방식의 영향으로 RF와 BT 기반 모형의 결과는 남북 방향으로 추정값이 선형적으로 급격히 증가하는 경향이 나타난다.

4. 결론

본 연구는 시공간적 변동 양상이 공간과 시공간 크리깅의 추정 결과에 미치는 영향을 탐색하는 것을 목적으로 한다. 이를 위하여 시공간적 변동 양상이 상이한 두 시점을 선정하고, 해당 시점에서 기계학습을 활용하여 1차 효과를 추정한 후, 공간 크리깅과 시공간 크리깅으로 2차 효과를 모델링하였다. 그 결과, 시공간적 변동이 작은 시점에서는 시공간 크리깅이 높은 추정 정확도를 나타냈다. 반면, 시공간적 변동이 큰 시점에서는 대체로 시공간적 효과를 연속적으로 반영하는 시공간 크리깅이 과대추정의 경향을 보였으며, 이 경우 단일 시점을 기준으로 공간적 효과만 고려한 크리깅이 더 높은 정확도를 제공하였다. 또한 1차 효과의 추정에 기계학습을 적용한 경우, 그렇지 않은 경우보다 전반적으로 높은 추정 정확도를 보였다. 이는 기계학습의 높은 유연성이 공간적, 시공간적 변동의 상당 부분을 1차 효과에서 설명함으로써 정확도 향상에 기여하는 것을 시사한다. 그러나 시

공간적 변동이 큰 시기에는 공간과 시공간 크리깅 간 추정값의 분포 차이가 크게 나타났으며, 시공간 크리깅이 현재 시점과는 변동 양상이 다른 시기의 데이터를 활용하여 인터폴레이션을 수행하기 때문인 것으로 해석된다.

본 연구는 인터폴레이션 수행에 있어 시공간적 변동 양상이 결과에 영향을 미친다는 점을 강조하며, 시공간적 변동 양상에 따라 적합한 모형의 선택이 필요함을 시사한다. 시공간 크리깅은 공간뿐 아니라 시공간적 자기상관이 완만하게 변화한다는 가정을 가지고 인터폴레이션을 수행하기에, 급변하는 시공간적 현상에 적용 시 유의가 필요하다. 더불어 기계학습이 시간적 요소를 더 중요하게 고려하여 1차 효과를 모델링할 경우, 본 연구에서 7월의 결과와 같이 시공간적으로 급변하는 양상을 포착하는 데 한계를 보일 수 있다. 이 연구는 다음과 같은 후속 연구로 이어질 수 있다. 먼저 본 연구는 특정 대기 오염물질을 사례로 경험적 데이터 결과만을 분석하였기에, 결과를 일반화할 수 없다는 한계를 보인다. 따라서 다양한 시공간적 변동 양상을 보이는 현상에 대한 연구가 필요하다. 다음으로 기계학습을 1차 효과 추정에 활용한 크리깅 기법이 추정 정확도를 향상시킨다는 점을 실증적으로 확인하였으나, 각각의 변동 요소가 추정 결과에 미치는 영향을 직접적으로 평가하지는 못하였다. 이에 따라 향후 연구에서는 1차 및 2차 효과가 설명하는 변동의 구조적 특성을 분해하고 기계학습의 특성에 따라 그 차이를 비교하는 분석이 요구된다. 또한 본 연구에서 활용한 공간 좌표 이외에 다른 형태의 공간적 변수를 활용한다면(Koo et al., 2024), 공간적 변동 양상을 다양하게 반영할 수 있을 것으로 기대된다.

사사

본 연구는 환경부 「기후변화특성화대학원사업」의 지원으로 수행되었습니다.

Conflict of Interest

No potential conflict of interest relevant to this article was reported.

References

- An, L., Tsou, M. H., Crook, S. E., Chun, Y., Spitzberg, B., Gawron, J. M., et al., 2015. Space-time analysis: Concepts, quantitative methods, and future directions. *Annals of the Association of American Geographers*, 105(5), 891–914. <https://doi.org/10.1080/00045608.2015.1064510>
- Andriy, B., 2019. *The hundred-page machine learning*. Andriy Burkov.

- Bailey, T. C., and Gatrell, A. C., 1995. *Interactive spatial data analysis*. Longman Scientific & Technical.
- Chiles, J. P., and Delfiner, P., 2012. *Geostatistics: Modeling spatial uncertainty*. John Wiley & Sons.
- Cressie, N., 2015. *Statistics for spatial data*. John Wiley & Sons.
- Erten, G. E., Yavuz, M., and Deutsch, C. V., 2022. Combination of machine learning and kriging for spatial estimation of geological attributes. *Natural Resources Research*, 31(1), 191–213. <https://doi.org/10.1007/s11053-021-10003-w>
- Gräler, B., Pebesma, E., and Heuvelink, G., 2016. Spatio-temporal interpolation using gstat. *The R Journal*, 8/1, 204–218. <https://cran.r-project.org/web/views/SpatioTemporal.html>
- Heuvelink, G. B. M., and Griffith, D. A., 2010. Space-time geostatistics for geography: A case study of radiation monitoring across parts of Germany. *Geographical Analysis*, 42(2), 161–179. <https://doi.org/10.1111/j.1538-4632.2010.00788.x>
- Journal, A. G., and Rossi, M. E., 1989. When do we need a trend model in kriging?. *Mathematical Geology*, 21(7), 715–739.
- Júnez-Ferreira, H. E., Hernández-Hernández, M. A., Herrera, G. S., González-Trinidad, J., Cappello, C., Maggio, S., and De Iaco, S., 2023. Assessment of changes in regional groundwater levels through spatio-temporal kriging: Application to the southern Basin of Mexico aquifer system. *Hydrogeology Journal*, 31, 1405–1423. <https://doi.org/10.1007/s10040-023-02681-y>
- Koo, H., Yoo, M., Seo, H., and Park, S., 2024. Exploring the impact of spatial autocorrelation on optimistic bias in cross-validation and assessing the effectiveness of spatial cross-validation. *Journal of the Korean Society of Surveying, Geodesy, Photogrammetry and Cartography*, 42(1), 1–13. <https://doi.org/10.7848/ksgpc.2024.42.1.1>
- Korea Environment Corporation, 2023. Accessing finalized measurement data. Available online: <https://deva.airkorea.or.kr/web/> (accessed on Feb. 7, 2025).
- Lee, S. I., 2001. Developing a bivariate spatial association measure: An integration of Pearson's r and Moran's I . *Journal of Geographical Systems*, 3, 369–385.
- Li, J., Heap, A. D., Potter, A., and Daniell, J. J., 2011. Application of machine learning methods to spatial interpolation of environmental variables. *Environmental Modelling and Software*, 26(12), 1647–1659. <https://doi.org/10.1016/j.envsoft.2011.07.004>
- Lin, J., Zhang, A., Chen, W., and Lin, M., 2018. Estimates of daily PM_{2.5} exposure in Beijing using spatio-temporal kriging model. *Sustainability*, 10, 2772. <https://doi.org/10.3390/su10082772>
- Meyer, H., Reudenbach, C., Hengl, T., Katurji, M., and Nauss, T., 2018. Improving performance of spatio-temporal machine learning models using forward feature selection and target-oriented validation. *Environmental Modelling & Software*, 101, 1–9. <https://doi.org/10.1016/j.envsoft.2017.12.001>
- Natekin, A., and Knoll, A., 2013. Gradient boosting machines, a tutorial. *Frontiers in Neurorobotics*, 7, Article 21. <https://doi.org/10.3389/fnbot.2013.00021>
- Shah, V., Jacob, D. J., Li, K., Silvern, R., Zhai, S., Liu, M., et al., 2020. Effect of changing NO_x lifetime on the seasonality and long-term trends of satellite-observed tropospheric NO₂ columns over China. *Atmospheric Chemistry and Physics*, 20(3), 1483–1495. <https://doi.org/10.5194/acp-20-1483-2020>
- Shao, Y., Ma, Z., Wang, J., and Bi, J., 2020. Estimating daily ground-level PM_{2.5} in China with random-forest-based spatiotemporal kriging. *Science of The Total Environment*, 740, Article 139761. <https://doi.org/10.1016/j.scitotenv.2020.139761>
- Van Zoest, V., Osei, F. B., Hoek, G., and Stein, A., 2020. Spatio-temporal regression kriging for modelling urban NO₂ concentrations. *International Journal of Geographical Information Science*, 34(5), 851–865. <https://doi.org/10.1080/13658816.2019.1667501>
- Wackernagel, H., 2003. *Multivariate geostatistics: An introduction with applications*. Springer.
- Zhan, Y., Luo, Y., Deng, X., Zhang, K., Zhang, M., Grieneisen, M. L., et al., 2018. Satellite-based estimates of daily NO₂ exposure in China using hybrid random forest and spatiotemporal kriging model. *Environmental Science and Technology*, 52(7), 4180–4189. <https://doi.org/10.1021/acs.est.7b05669>